Construção dos esquemas

Data Warehouse, UFPE. Entrega da aula de 03/11/2026, revisada depois do retorno do professor.
Equipe: jlsm2, jvcn, gflb, gvab, lmq2, mffa, thrb.

Reduzimos as consultas de 13 para 7, cada uma ligada a uma decisão de gestão acadêmica e descrita com população, período, medidas e agrupamentos. Escolhemos o gráfico de cada uma, ajustamos o que faltava nos esquemas e povoamos tudo com dados sintéticos. Os scripts rodaram no MySQL 8, o banco definido nos diagramas, e as 7 consultas executaram sem erro. Partimos das questões do TCC de Espíndola (UFPE, 2025) e as adaptamos aos campos que temos.

1. Consultas e escolha dos gráficos

"Agregada" é a estrela de fato_professor_disciplina, e "por aluno" é a de fato_professor_aluno. O SQL de cada consulta está em sql/05_consultas.sql.

C1. Considerando as matrículas de 2023.1 a 2025.2, para cada disciplina com pelo menos 100 matrículas, quantas reprovações houve, qual foi a taxa de reprovação, que parte dessas reprovações foi por falta e que parte das matrículas era de alunos repetindo a disciplina?

Decisão: A coordenação decide onde colocar as vagas de monitoria. O número de reprovações mostra quantos alunos a monitoria pode atingir, e a taxa mostra a gravidade. Quando a maior parte é por falta, reforço de conteúdo pode não bastar.

Estrela: Agregada e por aluno. **Gráfico:** Dispersão de matrículas por taxa de reprovação, com linhas nas medianas. Duas medidas precisam ser lidas juntas: um ranking só pela taxa destacaria disciplinas pequenas, e só por volume, as grandes. O quadrante de muitas matrículas e taxa alta é a prioridade.

C2. Considerando os alunos ativos ao fim de 2025.2, para cada disciplina, quantos já a cursaram sem aprovação e ainda a devem, separados por curso, quantos deles já reprovaram duas vezes ou mais, e a quantas turmas esse total equivale, usando a média de alunos por turma de 2025.1 e 2025.2? Mostrar as 10 disciplinas com mais pendentes.

Decisão: O departamento decide em quais disciplinas abrir ou ampliar turmas no próximo semestre. Esses alunos se somam à demanda regular de quem ainda vai cursar pela primeira vez, que fica fora desta conta.

Estrela: Por aluno e agregada. **Gráfico:** Barras horizontais empilhadas por curso. O comprimento mostra o total a absorver, e os segmentos mostram quais cursos pressionam a oferta. As turmas equivalentes entram como rótulo no fim de cada barra.

C3. Entre os alunos que ingressaram de 2018.1 a 2023.2 e chegaram ao fim do 2º semestre sem evadir, separados por curso e pelo número de reprovações nesses dois semestres (0, 1, 2, 3, 4 ou mais), que parte evadiu depois?

Decisão: A coordenação define o critério de entrada na tutoria: a partir de quantas reprovações o aluno é chamado. Só entra quem ainda estava no curso ao fim do 1º ano, porque é nesse momento que a decisão seria tomada.

Estrela: Por aluno. **Gráfico:** Colunas por número de reprovações, um painel por curso. As categorias são ordenadas e o que importa é onde a evasão salta. Painéis separados evitam misturar 15 colunas. O número de alunos aparece em cada coluna, porque alguns grupos são pequenos.

C4. Entre os alunos que ingressaram de 2018.1 a 2020.1, que já têm 12 semestres de histórico, que parte de cada curso já tinha evadido até cada semestre, do 1º ao 12º?

Decisão: A coordenação decide em que momento do curso concentrar as ações de permanência: onde a curva sobe mais rápido, a ação tende a chegar a tempo de mais alunos.

Estrela: Por aluno. **Gráfico:** Linhas acumuladas, uma por curso. O eixo é uma sequência de tempo, e a inclinação da linha mostra quando a evasão acontece. Usar sempre as mesmas turmas impede que a curva mude só porque os alunos observados mudaram.

C5. Ao fim de 2025.2, comparando o tempo de curso com o prazo previsto, quantos alunos ativos de cada curso estão no prazo, com até 2 semestres de atraso, com 3 a 4 e com 5 ou mais, e qual é a carga horária média já cursada em cada grupo?

Decisão: A coordenação dimensiona o plano de integralização: quantos alunos atender e por onde começar. Muito atraso com carga horária alta sugere um aluno perto de concluir.

Estrela: Por aluno. **Gráfico:** Barras horizontais empilhadas por curso, com a carga horária em tabela. Os grupos de atraso são partes ordenadas do total de ativos de cada curso. A carga horária é outra medida, então fica na tabela, sem eixo duplo.

C6. Para cada faixa econômica, considerando os ingressantes de 2018.1 a 2023.2, que parte evadiu? E, nas matrículas a partir do 2º período, que parte tinha assistência estudantil, e qual foi a taxa de aprovação com e sem o benefício?

Decisão: A gestão da assistência estudantil decide para quais faixas direcionar o benefício. Evasão alta com pouca cobertura aponta onde ampliar. A comparação começa no 2º período porque, nos dados sintéticos, calouros não recebem o benefício.

Estrela: Por aluno. **Gráfico:** Colunas agrupadas (com e sem benefício) por faixa, com evasão e cobertura em tabela. As faixas são ordenadas, e a distância entre as colunas é a informação. Evasão e cobertura ficam na tabela para evitar um segundo eixo. O resultado mostra associação: não prova efeito do benefício.

C7. Considerando de 2023.1 a 2025.2 e só professores com pelo menos 30 matrículas na disciplina, para cada disciplina com dois professores ou mais, quais são a menor e a maior taxa de reprovação entre eles, e qual é a diferença em pontos percentuais? Mostrar as 10 maiores diferenças.

Decisão: A coordenação pedagógica decide em quais disciplinas reunir os professores para alinhar plano de ensino e critérios de avaliação. A consulta aponta disciplinas, não serve para avaliar professores, e não mede as diferenças entre as turmas de cada um.

Estrela: Agregada e view de professores. **Gráfico:** Intervalo (menor e maior taxa ligadas por um segmento), por disciplina. O segmento mostra ao mesmo tempo o nível da disciplina e a distância entre os extremos, o que uma barra só com a diferença esconderia. Turmas com mais de um professor contam para todos eles.

Duas regras valem para todas as consultas. As taxas são calculadas a partir das contagens, nunca como média de taxas de turmas, porque turmas pequenas pesariam igual às grandes. E a evasão de turmas recentes ainda pode subir, por isso C3, C4 e C6 limitam o período de ingresso.

2. Ajustes nos esquemas

Mantivemos os grãos, as chaves e as dimensões compartilhadas. Foram cinco acréscimos:

Ajuste	Por que	Consultas
situacao_vinculo e **id_data_saida** em dim_aluno	O esquema registrava matrículas, mas não dizia quem concluiu ou evadiu, nem quando.	C2, C3, C4, C5, C6
semestres_previstos em dim_curso	Sem o prazo de cada curso, não há como saber quem está atrasado.	C5
periodo_aluno em fato_professor_aluno	Guarda quantos semestres se passaram desde o ingresso. Calculado na carga, dispensa uma tabela de matriz curricular por curso.	C3, C6
qtd_trancamentos em fato_professor_disciplina	As quatro contagens de situação não fechavam com qtd_matriculados quando havia trancamento, e as taxas ficavam com a base errada.	C1, C7
View **vw_turma_professor**	Transforma os três papéis de professor em linhas, sem alterar as tabelas. Evita três joins em cada consulta. O peso reparte turmas com mais de um professor em somas gerais.	C7

Pendências do grupo. Ainda falta confirmar se a situação de vínculo e o semestre de saída estão nos PDFs de origem. Isso pesa em 5 das 7 consultas: C2, C3, C4, C5 e C6 dependem da situação, e C3 e C4 também do semestre de saída. Só C1 e C7 funcionam sem esses campos. Sexo e faixa etária, usados no TCC, não foram incluídos porque não sabemos se a fonte traz esses dados. Os ajustes nos diagramas do DrawSQL estão listados em docs/mudancas_esquemas.md, e o arquivo sql/01_ddl.sql já tem a versão final.

3. Dados sintéticos

O gerador (gerador/gerar_dados.py) simula cada aluno semestre a semestre: escolhe disciplinas pendentes, sorteia o resultado, repete o que reprovou e decide se ele conclui ou evade. A semente é fixa, então o resultado é sempre igual. A fato agregada não é sorteada: sai da fato por aluno em SQL, então as duas estrelas sempre fecham.

Tabela	Linhas	Conteúdo
dim_data	16	2018.1 a 2025.2
dim_curso	3	CC, EC e SI
dim_disciplina	42	Currículo fictício
dim_professor	40	Pseudônimos
dim_turma_aluno	72	Coortes de ingresso
dim_aluno	1.433	433 concluíram, 619 evadiram, 381 ativos
dim_turma_disciplina	875	197 turmas com mais de um professor
fato_professor_aluno	30.992	Uma linha por matrícula
fato_professor_disciplina	2.211	Derivada da fato por aluno

Regras usadas. Nota a partir de 7 aprova por nota. Abaixo de 3, o aluno reprova sem ir para a final. De 3 a 6,99, ele faz a final e precisa de média final de pelo menos 5. Mais de 25% da carga horária em faltas reprova por falta. Trancamento fica sem nota e sem faltas, e só aprovação soma carga horária. O gerador não simula a prova final em separado: guarda apenas a nota final, e as aprovadas na final ficam entre 5 e 6,99.

O que estes dados não são. Nenhum número aqui descreve a UFPE. Colocamos de propósito alguns efeitos para o painel ter o que mostrar: disciplinas com dificuldades diferentes, primeiros períodos mais duros, notas maiores em 2020 e 2021 e uma pequena vantagem nas faixas de renda mais altas. O tipo de cota não tem efeito direto no gerador. O risco de evasão no gerador cresce com as reprovações, o que alimenta C3. O benefício e o professor não têm efeito no gerador, então as diferenças em C6 e C7 são acaso. Qualquer padrão nos resultados reflete essas escolhas, não uma descoberta. Alunos e professores são pseudônimos, e os anos de 2014 a 2017 foram simulados só para 2018 não começar apenas com calouros.

Verificação. Os 15 testes de sql/06_validacao.sql retornaram zero erros. Eles conferem, entre outras coisas, se as duas estrelas têm as mesmas matrículas, notas e faltas, se as situações e as faixas fecham com os totais, se a nota combina com a situação e se não há matrícula antes do ingresso ou depois da saída.

4. Como reproduzir

Com um MySQL 8 em execução, na raiz do repositório:

```
./scripts/carregar.sh -uroot -p
mysql -uroot -p --table < sql/05_consultas.sql
```

A pasta dados/csv traz as mesmas tabelas em CSV para quem preferir importar no painel.