Construção dos esquemas

Data Warehouse, UFPE. Entrega da aula de 03/11/2026, sobre os esquemas PDFs e PDFs 2.
Equipe: jlsm2, jvcn, gflb, gvab, lmq2, mffa, thrb.

Levantamos 13 consultas sobre as duas estrelas, escolhemos o gráfico de cada uma, ajustamos o que faltava nos esquemas e povoamos tudo com dados sintéticos. Os scripts rodaram no MySQL 8, o banco definido nos diagramas, e as 13 consultas executaram sem erro. Partimos das questões do TCC de Espíndola (UFPE, 2025) e as adaptamos aos campos que temos, como turma, professor, assistência estudantil e faixa econômica.

1. Consultas e escolha dos gráficos

"Agregada" é a estrela de fato_professor_disciplina, e "Por aluno" é a de fato_professor_aluno. O SQL de cada consulta está em sql/05_consultas.sql.

C1. Como a taxa de aprovação de cada disciplina evoluiu ao longo dos 16 semestres?

Estrela: Agregada. Gráfico: Linhas, uma por disciplina, com filtro de disciplina.

O tempo é contínuo e ordenado, e a linha mostra tendência e mudança de patamar. Em colunas, 16 semestres vezes 42 disciplinas dariam 672 barras. Mesmo em linhas, 42 juntas ficariam ilegíveis, então o filtro deixa comparar poucas disciplinas por vez.

C2. Quais são as 10 disciplinas com maior taxa de reprovação, e qual é a taxa de cada uma?

Estrela: Agregada. Gráfico: Barras horizontais ordenadas (10 maiores).

Compara valores entre categorias sem ordem própria. Os nomes longos cabem na horizontal e a ordenação já entrega o ranking. Pizza não serve, porque as taxas não somam 100%.

C3. Nas disciplinas críticas, como as matrículas se dividem entre aprovação por nota, aprovação na final, reprovação por nota, reprovação por falta e trancamento?

Estrela: Agregada. Gráfico: Barras empilhadas em 100%.

Cada barra é um todo dividido em partes, e várias pizzas seriam difíceis de comparar. Separar reprovação por nota e por falta importa, porque a primeira aponta dificuldade de conteúdo e a segunda, abandono da disciplina.

C4. Como as notas finais de cada curso se distribuem entre as faixas da regra de avaliação?

Estrela: Agregada. Gráfico: Colunas por faixa, em % do curso.

As faixas têm ordem, então colunas lado a lado funcionam, e o percentual evita que o curso maior pareça pior. Não é um histograma: as faixas seguem a regra da disciplina, e não uma largura fixa. A de 0 a 2,9 é de quem não chega à final, e a de 3 a 6,9 concentra quem vai para ela. Essa faixa tem 4 pontos e a de 7 a 7,9 tem 1, então parte da altura vem da largura. Vale deixar isso escrito no painel.

C5. Como a taxa de reprovação de cada disciplina crítica variou de um semestre para outro, e como essa variação acompanha o professor que deu a disciplina?

Estrela: Agregada + ponte. Gráfico: Mapa de calor (disciplina x semestre), com o professor na dica.

São duas dimensões e 128 valores. A cor em um só tom destaca os pontos fora do padrão, enquanto 8 linhas sobrepostas ficariam ilegíveis. A dica de cada célula mostra quem deu a disciplina naquele semestre, para ver se as piores células coincidem com a troca de professor. Uma célula pode ter mais de uma turma e mais de um professor, e a coincidência não prova que o professor causou a variação.

C6. Como a taxa de reprovação de cada oferta se relaciona com a média de faltas dessa oferta?

Estrela: Agregada. Gráfico: Dispersão, um ponto por oferta.

É a relação entre duas medidas numéricas, e cada ponto mantém a oferta visível. Usamos a média de faltas, e não a soma, porque a soma cresce com o tamanho da turma. O gráfico mostra associação, não causa.

C7. Dentro de uma mesma disciplina, como a taxa de aprovação, a nota média e o número de alunos variam entre os professores?

Estrela: Agregada + ponte. Gráfico: Tabela com barra de dados, filtrada por disciplina.

Aqui o valor exato e o número de alunos importam. O filtro compara professores só dentro da mesma disciplina, porque um ranking geral puniria quem ensina as matérias difíceis.

C8. Como as reprovações se distribuem conforme o período em que os alunos estão no curso?

Estrela: Por aluno. Gráfico: Colunas por período.

Os períodos são discretos e ordenados, e a coluna deixa claro onde está o pico. A base é maior nos primeiros períodos, então convém mostrar o total de matrículas na dica do gráfico.

C9. Em cada turma de ingresso, qual é a proporção de alunos que concluíram, que seguem ativos e que evadiram?

Estrela: Por aluno. Gráfico: Barras empilhadas em 100% (concluiu, ativo, evadiu).

Toda turma de ingresso soma 100%. A parte de ativos evita uma leitura errada: as turmas que entraram há pouco concluíram pouco porque ainda estão no curso, e a evasão delas ainda pode subir.

C10. Como as taxas de reprovação e de evasão variam entre os tipos de cota em cada faixa econômica?

Estrela: Por aluno. Gráfico: Dois gráficos de barras horizontais, com filtro de faixa.

Reprovação e evasão ficam em gráficos separados, sem eixo duplo, que sugeriria relações que dependem só da escala. O número de alunos aparece junto, porque alguns grupos são pequenos e oscilam muito.

C11. Quanto o tempo de conclusão de cada curso se afasta do prazo previsto?

Estrela: Por aluno. Gráfico: Barras com marcador do prazo previsto.

O marcador compara cada curso com a própria meta, já que os prazos são diferentes. Sem ferramenta para isso, colunas agrupadas (previsto e real) cumprem o papel. A base são só os alunos que concluíram.

C12. Como a taxa de aprovação muda da 1ª para a 2ª tentativa, e para a 3ª ou mais, na mesma disciplina?

Estrela: Por aluno. Gráfico: Colunas (1ª, 2ª, 3ª ou mais).

São só três categorias ordenadas e uma medida, então o gráfico mais simples basta.

C13. Como a taxa de aprovação de beneficiários e de não beneficiários de assistência estudantil evoluiu ao longo dos semestres?

Estrela: Agregada. Gráfico: Duas linhas.

Pelo mesmo motivo de C1, e a distância entre as linhas é a informação. Atenção: no gerador só há benefício a partir do 2º período, então o grupo sem benefício inclui calouros e a diferença não prova efeito da assistência estudantil.

Três regras valem para todo o painel. As taxas devem ser calculadas a partir das contagens, nunca como média de taxas de turmas, porque turmas pequenas pesariam igual às grandes. A média de notas agregada é soma_notas_finais / qtd_notas_validas, e a mediana não se agrega, como o próprio diagrama já avisa. Por fim, os indicadores gerais (taxa de aprovação, nota média, evasão) ficam em cartões no topo, porque são um número só e pedem leitura imediata.

2. Ajustes nos esquemas

Mantivemos os grãos, as chaves e as dimensões compartilhadas. Foram cinco acréscimos:

Ajuste	Por que	Consultas
situacao_vinculo e **id_data_saida** em dim_aluno	O esquema registrava matrículas, mas não dizia quem concluiu ou evadiu, nem quando.	C9, C10, C11
semestres_previstos em dim_curso	Sem o prazo de cada curso, não há com o que comparar o tempo de conclusão.	C11
periodo_aluno em fato_professor_aluno	Guarda quantos semestres se passaram desde o ingresso. Calculado na carga, dispensa uma tabela de matriz curricular por curso.	C8
qtd_trancamentos em fato_professor_disciplina	As quatro contagens de situação não fechavam com qtd_matriculados quando havia trancamento, e as taxas ficavam com a base errada.	C1, C2, C3, C5, C6, C7, C13
View **vw_turma_professor**	Transforma os três papéis de professor em linhas, sem alterar as tabelas. Evita três joins em cada consulta. O peso reparte turmas com mais de um professor em somas gerais.	C5, C7

Pendências do grupo. Ainda falta confirmar se a situação de vínculo e o semestre de saída estão nos PDFs de origem. Se não estiverem, C9, C10 e C11 perdem a base com os dados reais. Sexo e faixa etária, usados no TCC, não foram incluídos porque não sabemos se a fonte traz esses dados. Os ajustes nos diagramas do DrawSQL estão listados em docs/mudancas_esquemas.md, e o arquivo sql/01_ddl.sql já tem a versão final.

3. Dados sintéticos

O gerador (gerador/gerar_dados.py) simula cada aluno semestre a semestre: escolhe disciplinas pendentes, sorteia o resultado, repete o que reprovou e decide se ele conclui ou evade. A semente é fixa, então o resultado é sempre igual. A fato agregada não é sorteada: sai da fato por aluno em SQL, então as duas estrelas sempre fecham.

Tabela	Linhas	Conteúdo
dim_data	16	2018.1 a 2025.2
dim_curso	3	CC, EC e SI
dim_disciplina	42	Currículo fictício
dim_professor	40	Pseudônimos
dim_turma_aluno	72	Coortes de ingresso
dim_aluno	1.433	433 concluíram, 619 evadiram, 381 ativos
dim_turma_disciplina	875	197 turmas com mais de um professor
fato_professor_aluno	30.992	Uma linha por matrícula
fato_professor_disciplina	2.211	Derivada da fato por aluno

Regras usadas. Nota a partir de 7 aprova por nota. Abaixo de 3, o aluno reprova sem ir para a final. De 3 a 6,99, ele faz a final e precisa de média final de pelo menos 5. Mais de 25% da carga horária em faltas reprova por falta. Trancamento fica sem nota e sem faltas, e só aprovação soma carga horária. O gerador não simula a prova final em separado: guarda apenas a nota final, e as aprovadas na final ficam entre 5 e 6,99.

O que estes dados não são. Nenhum número aqui descreve a UFPE. Colocamos de propósito alguns efeitos para o painel ter o que mostrar: disciplinas com dificuldades diferentes, primeiros períodos mais

duros, notas maiores em 2020 e 2021 e uma pequena vantagem nas faixas de renda mais altas. O tipo de cota não tem efeito direto no gerador. Qualquer padrão nos gráficos reflete essas escolhas, não uma descoberta. Alunos e professores são pseudônimos, e os anos de 2014 a 2017 foram simulados só para 2018 não começar apenas com calouros.

Verificação. Os 15 testes de sql/06_validacao.sql retornaram zero erros. Eles conferem, entre outras coisas, se as duas estrelas têm as mesmas matrículas, notas e faltas, se as situações e as faixas fecham com os totais, se a nota combina com a situação e se não há matrícula antes do ingresso ou depois da saída.

4. Como reproduzir

Com um MySQL 8 em execução, na raiz do repositório:

```
./scripts/carregar.sh -uroot -p
mysql -uroot -p --table < sql/05_consultas.sql
```

A pasta dados/csv traz as mesmas tabelas em CSV para quem preferir importar no painel.